

Autonómne riadenie robotického ramena pomocou posilňovaného učenia

Bc. Ivan Demchenko, Bc. Danylo Kravchenko

Katedra počítačov a informatiky

Technická univerzita v Košiciach

Košice, Slovensko

Abstract—Táto technická správa opisuje našu implementáciu RL agenta pre autonómne riadenie robotického ramena v prostredí Fetch Pick and Place. Hlavným cieľom bolo naučiť agenta uchopiť kocku a presunúť ju na požadované miesto. V práci sme porovnali dva algoritmy, Proximal Policy Optimization (PPO) a Soft Actor-Critic (SAC). Sledovali sme hlavne čas učenia, úspešnosť dosiahnutia cieľa, úspešnosť uchopenia, pick-and-place úspešnosť, počet kolízií, priemernú odmenu a vplyv rôznych reward funkcií. Výsledky ukázali, že SAC po 1 milióni krokov zvládol prísnejšiu air-goal úlohu, ale PPO sa v rovnakých podmienkach nenaučil spoľahlivo uchopiť a presunúť objekt. Dodatočné SAC curriculum behy pre tri rôzne seedy potvrdili stabilitu výsledku.

Index Terms—robotické rameno, posilňované učenie, PPO, SAC, Gymnasium-Robotics, FetchPickAndPlace

I. ÚVOD A STAV PROBLEMATIKY

Autonómna manipulácia objektov je jedna z typických úloh robotiky, ale v praxi nie je jednoduchá. Robotické rameno musí naraz riešiť pohyb koncového efektora, kontakt s objektom, otvorenie a zatvorenie gripperu a aj to, že odmena za dobré správanie príde často až na konci epizódy. Pri klasickom riadení by bolo potrebné presne opísať model robota, objektu a kontaktov. Pri pick-and-place úlohách je to dosť náročné, lebo aj malá zmena počiatočnej polohy kocky môže zmeniť celý priebeh manipulácie.

Preto sme použili posilňované učenie (reinforcement learning, RL). Agent v ňom skúša akcie v prostredí, sleduje stav a postupne sa učí podľa reward signálu. Výhoda RL je, že nemusíme ručne naprogramovať celú stratégiu uchopenia. Na druhej strane učenie potrebuje veľa krokov a výsledok dosť závisí od návrhu odmeny. Pri riedkej odmene agent často dlho nevie, ktoré akcie ho vlastne posúvajú k cieľu.

V práci sme použili prostredie Fetch Pick and Place z Gymnasium-Robotics [1]. Je to simulačná úloha, kde má robotické rameno presunúť kocku zo stola do cieľa. Experimenty sú postavené na knižnici Stable-Baselines3 [2]. Porovnávali sme PPO [3] a SAC [4], pretože oba algoritmy sa často používajú pri spojitom riadení. Najviac nás zaujímalo, či algoritmus naozaj zdvihne objekt, alebo či iba nájde jednoduchší spôsob, napríklad posúvanie po stole.

II. FORMULÁCIA ÚLOHY A PROSTREDIE

Prostredie používa API typu GoalEnv. Pozorovanie je slovník s tromi časťami: stav robota a objektu, dosiahnutý cieľ (*achieved goal*) a požadovaný cieľ (*desired goal*). Akčný priestor je spojitý a má štyri hodnoty. Tri hodnoty riadia pohyb gripperu v priestore a štvrtá hodnota riadi otvorenie alebo zatvorenie gripperu.

Pri základnej verzii prostredia sa môže stať, že agent splní cieľ aj tým, že kocku iba posunie po stole. Pre zadanie to však nie je úplne správne, pretože cieľom je uchopiť objekt a presunúť ho. Z tohto dôvodu sme použili aj *air-goal*¹ úpravu, kde je cieľ nad stolom. Agent potom musí kocku zdvihnúť, inak sa k cieľu nedostane.

Do vyhodnotenia sme doplnili vlastné metriky. Uchopenie považujeme za úspešné, keď je objekt zdvihnutý nad stolom a je blízko gripperu. Pick-and-place úspech znamená, že objekt skončí v cieľi a cieľ je zároveň vo vzduchu. Kolízie počítame ako neočakávané kontakty v MuJoCo simulácii medzi objektom a robotom. Kontakty s prstami gripperu, stolom a podlahou neberieme ako chybu, lebo pri tejto úlohe sú prirodzené.

III. POUŽITÉ METÓDY

A. PPO

Proximal Policy Optimization je on-policy² algoritmus. To znamená, že sa učí hlavne z dát, ktoré práve nazbierala aktuálna verzia politiky. Jeho hlavná myšlienka je jednoduchá: pri aktualizácii politiky nedovoľiť príliš veľký skok, aby sa učenie nerozpadlo. Používa sa pomer pravdepodobností novej a starej politiky

$$r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)} \quad (1)$$

a klipovaná cieľová funkcia

$$L^{CLIP}(\theta) = \mathbb{E}_t [\min(r_t(\theta)A_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)A_t)]. \quad (2)$$

Klipovanie znižuje riziko, že sa politika po jednej aktualizácii príliš zmení. Pre robotickú manipuláciu je však nevýhoda v tom, že PPO väčšinou nepoužíva staršie

¹Air-goal znamená, že cieľová pozícia je vo vzduchu, nie na stole. Agent preto musí objekt reálne zdvihnúť.

²On-policy algoritmus sa učí hlavne z dát nazbieraných aktuálnou politikou, takže staršie pokusy využíva iba obmedzene.

skúsenosti opakovane. Ak sa úspešné uchopenie objaví zriedka, algoritmus môže potrebovať veľmi veľa pokusov.

B. SAC

Soft Actor-Critic je off-policy actor-critic algoritmus. Na rozdiel od PPO si ukladá skúsenosti do replay buffera³ a vie ich použiť viackrát. Okrem odmeny maximalizuje aj entropiu politiky, takže agent viac skúša rôzne akcie. Cieľ možno zapísať ako

$$J(\pi) = \sum_t \mathbb{E}_{(s_t, a_t) \sim \rho_\pi} [r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot | s_t))]. \quad (3)$$

Replay buffer je pri manipulácii dôležitý, pretože aj čiastočne dobré epizódy sú cenné. Ak sa agent napríklad naučí dostať ku kocke alebo ju trochu zdvihnúť, táto skúsenosť sa môže pri tréningu použiť znova. V našich experimentoch sa ukázalo, že SAC z toho výrazne profitoval, aj keď tréning trval dlhšie.

C. Reward funkcie

Testovali sme viac typov odmeny. Sparse reward je pôvodná riedka odmena z prostredia a agent z nej dostáva málo informácie. Dense reward dáva hustejší signál podľa vzdialenosti od cieľa. Shaped reward sme použili preto, aby agent dostával spätnú väzbu aj za medzikroky: priblíženie grippera ku kocke, priblíženie objektu k cieľu, zdvihnutie objektu, bonus za úspech a menšiu penalizáciu veľkosti akcie:

$$r = -w_g d(o, g) - w_e d(e, o) + w_l h(o) + b_s I_s - w_a \|a\|. \quad (4)$$

Penalized shaped reward pridáva ešte trest za neočakávané kolízie. Chceli sme overiť, či takáto penalizácia zlepši stabilitu učenia alebo správanie robota.

IV. DIZAJN EXPERIMENTOV

Experimenty sme navrhli podľa kritérií zo zadania: dĺžka učenia, počet úspešných uchopení, počet kolízií a vplyv reward funkcií. Finálne modely sme vyhodnocovali deterministicky na 100 epizódach, aby sa dali výsledky ľahko porovnať. Základné nastavenie je v tabuľke I.

TABLE I
ZÁKLADNÉ NASTAVENIE EXPERIMENTOV

Parameter	Hodnota
Prostredie	FetchPickAndPlace
Knižnica	Stable-Baselines3
Algoritmy	PPO, SAC
Seed	42; pre SAC curriculum aj 123 a 2026
Finálne učenie	1,000,000 krokov
Reward ablation	300,000 krokov
Evaluácia	100 epizód
Air-goal cieľ	zapnutý pre finálne porovnanie

Finálne porovnanie používa rovnaké podmienky pre PPO aj SAC: shaped reward, air-goal cieľ, seed 42 a 1

³Replay buffer je pamäť predchádzajúcich prechodov prostredia, z ktorej sa agent môže učiť opakovane.

milión tréningových krokov. Takto sme chceli porovnať, či algoritmy zvládnu prísnejšiu úlohu, kde nestačí tlačiť objekt po stole. Okrem toho sme urobili reward ablation s rozpočtom 300 tisíc krokov, kde sme porovnali dense, shaped a penalized reward. Túto časť berieme hlavne ako doplnkovú analýzu stability, nie ako finálne riešenie celej úlohy.

V. IMPLEMENTAČNÁ METODOLÓGIA

Projekt sme upravili tak, aby sa experimenty dali spúšťať opakovane a bez ručného prepisovania kódu. Nastavenia sú uložené v YAML konfiguráciách a sú rozdelené podľa algoritmu na PPO a SAC. V konfigurácii je prostredie, hyperparametre, počet tréningových krokov, počet paralelných prostredí a evaluačné nastavenia. Každý beh ukladal konfiguráciu, metadáta, finálny model a evaluačné výsledky, takže sa dali spätne porovnať konkrétne nastavenia.

Dôležitú časť tvorili wrappery prostredia. Air-goal wrapper posúva cieľ nad stôl, metrics wrapper pridáva grasp/pick/kolízne metriky a shaped reward wrapper nahrádza pôvodnú odmenu vlastnou reward funkciou. Pri wrapperoch sme museli zachovať GoalEnv API, aby algoritmy v Stable-Baselines3 fungovali správne.

Pri hodnotení sme použili evaluačné metriky po ukončení učenia a tréningové metriky z monitor logov. Evaluačné metriky na 100 epizódach ukazujú praktickú použiteľnosť modelu, zatiaľ čo priebeh odmien a rolling štandardná odchýlka pomáhajú odhadnúť stabilitu učenia.

Pri priamom PPO vs SAC porovnaní sme použili rovnaký seed a rovnaký počet evaluačných epizód. RL vie byť citlivé na seed, inicializáciu aj hyperparametre, preto sme finálnu SAC curriculum verziu doplnili ešte o ďalšie dva seedy. Táto časť už nie je úplne rovnaký 1M-step porovnávací experiment, ale slúži na overenie, či najlepší SAC postup nie je náhodný výsledok jedného behu.

VI. VÝSLEDKY

A. Samostatné tréningové behy

Okrem finálneho porovnania sme počas práce spustili viac samostatných behov. Tieto tréningy nám pomohli zistiť, ktoré nastavenia majú zmysel ďalej rozvíjať. Najskôr sme skúšali kratšie 300k behy pre PPO a SAC, potom sme nechali bežať úspešný SAC na 1M krokov s air-goal cieľom. Neskôr bol doplnený ešte SAC curriculum beh, kde bol tréning rozdelený na fázy *reach object*, *lift object* a *place object*. Prehľad PPO behov je v tabuľke II a prehľad SAC behov v tabuľke III.

TABLE II
SAMOSTATNÉ PPO TRÉNINGY

Reward	Kroky	Čas [s]	Odmena	Goal	Grasp
sparse	300k	437.5	-49.00	2/100	1/100
dense	300k	394.1	-12.86	2/100	0/100
shaped	300k	401.0	-12.19	2/100	0/100

TABLE III
SAMOSTATNÉ SAC TRÉNINGY

Reward/beh	Kroky	Čas [s]	Odmena	Goal	Grasp/Pick
sparse HER	300k	4124.7	-42.36	20/100	3/100 / -
dense	300k	3265.2	-12.86	2/100	0/100 / -
shaped	300k	3281.3	-12.64	2/100	0/100 / -
air shaped	1M	8712.3	130.63	100/100	100/100
curr. s42	400k	3281.8	309.93	100/100	100/100
curr. s123	500k	4477.1	301.33	100/100	100/100
curr. s2026	600k	8458.9	323.88	100/100	100/100

Z tabuliek vidno, že krátke 300k tréningy boli užitočné hlavne ako orientačné testy. PPO sa v nich nedostal k reálnej manipulácii. SAC so sparse HER [5] dosiahol 20/100 úspešných cieľov, ale uchopenie bolo stále slabé. Skutočný zlom nastal až pri dlhšom SAC air-goal shaped behu, kde model dosiahol 100/100 úspechov. Curriculum verzia tento výsledok zopakovala pre všetky tri testované seedy. Jednotlivé behy sa automaticky zastavili po 400k, 500k a 600k krokoch, keď bola splnená hranica pick success rate.

Tabuľka IV ukazuje hlavný výsledok práce. PPO sa po jednom milióni krokov nenaučil riešiť air-goal úlohu. V evaluácii mal 0/100 úspechov pre cieľ, uchopenie aj pick-and-place metriku. SAC v rovnakých podmienkach dosiahol 100/100 úspešných epizód vo všetkých troch metrikách. PPO bol síce časovo rýchlejší, ale v tomto prípade rýchly tréning nestačil, lebo výsledná politika nebola použiteľná.

Za použiteľnú politiku považujeme takú politiku, ktorá nielen splní geometrickú podmienku cieľa, ale zároveň objekt uchopí, zdvihne a presunie bez neočakávaných kolízií. PPO túto hranicu po 1 milióni krokov nedosiahol hlavne preto, že air-goal úloha má dlhý reťazec potrebných akcií: prísť ku kocke, zatvoriť gripper, zdvihnúť objekt a až potom ho presunúť. Ako on-policy algoritmus používal PPO iba čerstvo nazbierané trajektórie, takže zriedkavé čiastočne dobré pokusy sa nevyužívali opakovane tak ako pri replay bufferi v SAC. Záporná priemerná odmena a nulové grasp/pick metriky ukazujú, že agent sa nedostal ani k stabilnej fáze uchopenia.

TABLE IV
FINÁLNE POROVNANIE NA 1M AIR-GOAL SHAPED ÚLOHE

Alg.	Čas [s]	Odmena	Success	Grasp	Pick	Kol./ep.
PPO	265.6	-13.03	0%	0%	0%	0.00
SAC	8712.3	130.63	100%	100%	100%	0.00

Metriky success, grasp a pick sú v tabuľke uvedené ako success rate z 100 deterministických evaluačných epizód. Kol./ep. znamená priemerný počet neočakávaných kolízií na jednu epizódu.




Fig. 1. Porovnanie PPO a SAC na finálnej 1M air-goal shaped úlohe.

Najúspešnejší samostatný postup bol SAC curriculum air. Agent sa neučil naraz celú manipuláciu, ale postupne prešiel od priblíženia ku kocke, cez zdvihnutie objektu až k stabilnému presunu do cieľa. Prvé úspešné epizódy sa objavili približne pri 150k až 232k krokoch podľa seedu.




Fig. 2. Kumulatívna odmena epizódy počas najúspešnejšieho SAC curriculum tréningu.

Tabuľka V ukazuje dodatočné vyhodnotenie SAC curriculum behov. Všetky tri seedy dosiahli 100/100 úspešných cieľov, uchopení aj pick-and-place epizód. Priemer cez tri seedy bol $500k \pm 100k$ krokov a 5405.9 ± 2710.7 sekundy.

TABLE V
SAC CURRICULUM MULTI-SEED VÝSLEDKY

Seed	Kroky	Čas [s]	Odmena	Goal	Pick	Kol.
42	400k	3281.8	309.93	100/100	100/100	0.00
123	500k	4477.1	301.33	100/100	100/100	0.00
2026	600k	8458.9	323.88	100/100	100/100	0.00

Reward ablation v tabuľke VI ukazuje, že 300 tisíc krokov nestačilo na spoľahlivé vyriešenie úlohy. Dense reward mal najnižšiu rolling štandardnú odchýlku, teda priebeh odmien bol pokojnejší. Úspešnosť však ostala veľmi nízka. Shaped reward viac kolísal, pretože odmeňoval aj čiastkové fázy manipulácie, napríklad priblíženie ku kocke alebo jej zdvihnutie. Penalizácia kolízií pri tomto krátkom rozpočte nepriniesla viditeľné zlepšenie. Všetky 300k konfigurácie ostali pod 3/100 úspešných cieľových epizód, preto ich berieme skôr ako porovnanie ranej exploračie než ako finálny ranking reward funkcií.

TABLE VI
REWARD ABLATION S ROZPOČTOM 300K KROKOV

Alg.	Reward	Čas [s]	Odmena	Goal	Std20
PPO	dense	394.1	-12.86	2/100	1.47
PPO	shaped	401.0	-12.19	2/100	4.61
PPO	penalized	318.3	-13.74	2/100	4.57
SAC	dense	3265.2	-12.86	2/100	1.37
SAC	shaped	3281.3	-12.64	2/100	4.89
SAC	penalized	2494.2	-12.97	3/100	4.93

Presnejšie porovnanie shaped a penalized reward ukazuje, že penalizácia kolízií síce znížila počet kontaktov počas tréningu, ale nezlepšila finálne správanie. Pri PPO klesli tréningové kolízie zo 970 na 254, teda o 73.8%, ale goal success ostal 2/100 a grasp aj pick success ostali 0/100. Pri SAC klesli tréningové kolízie z 219 na 143, teda o 34.7%, ale goal success sa zlepšil iba z 2/100 na 3/100 a grasp/pick success ostali 0/100. Samotné zníženie kontaktov teda ešte nie je dôkaz bezpečnej a použiteľnej manipulácie.




Fig. 3. Porovnanie reward funkcií pre PPO a SAC pri 300k krokoch.

VII. ANALÝZA PODEA KRITÉRIÍ ZADANIA

Zadanie požaduje porovnať algoritmy z viacerých strán. Prvé kritérium je dĺžka učenia. Tu vyzerá lepšie PPO, pretože 1 milión krokov trval približne 265.6 sekundy, zatiaľ čo SAC potreboval 8712.3 sekundy. Tento údaj však sám o sebe nestačí. PPO bolo rýchlejšie, ale nenaučilo sa úlohu. SAC bolo pomalšie, ale výsledný model už objekt spoľahlivo uchopil a presunul.

Druhé kritérium je počet úspešných uchopení. Túto metriku považujeme za veľmi dôležitú, lebo samotné *is success* nemusí vždy znamenať reálne uchopenie. V air-goal experimente dosiahol PPO 0 úspešných uchopení zo 100 epizód. SAC dosiahol 100 zo 100. To ukazuje, že SAC sa naučilo skutočnú manipuláciu, nie iba náhodné priblíženie objektu k cieľu.

Tretie kritérium je počet kolízií. Pri finálnom vyhodnotení bola priemerná hodnota neočakávaných kolízií nulová pre oba algoritmy. Pri PPO to ale neznamená dobrú politiku, pretože agent s objektom úspešne nemanipuloval. Pri SAC je tento výsledok dôležitejší, lebo nulové kolízie boli dosiahnuté spolu so 100% úspešnosťou. Pri penalized reward sa zároveň ukázalo, že zníženie tréningových kolízií samo o sebe nestačí: PPO znížil kontakty o 73.8% a SAC o 34.7%, ale finálne uchopenie a pick-and-place úspešnosť sa pri 300k krokoch nezlepšili.

Štvrté kritérium je vplyv reward funkcií. Dense reward bol pri 300k behoch najstabilnejší podľa rolling standard-

nej odchýlky, ale úlohu nevyriešil. Shaped a penalized reward mali väčšiu variabilitu, lebo reagovali na viac častí správania. To nemusí byť zlé, pretože agent dostáva viac informácie o tom, čo robí správne. Finálny výsledok SAC so shaped air-goal úlohou naznačuje, že reward shaping bol pre úspešné učenie dôležitý.

VIII. DISKUSIA

Výsledky dobre ukazujú rozdiel medzi PPO a SAC. PPO bolo rýchle, ale v air-goal úlohe nenašlo stabilnú postupnosť akcií: prísť ku kocke, zatvoriť gripper, zdvihnúť objekt a presunúť ho do cieľa. SAC bol pomalší, no vďaka replay bufferu a väčšej exploračii sa vedel opakovane učiť aj z čiastočne dobrých pokusov.

Ak by sme chceli PPO ďalej zlepšovať, ako prvý krok by sme odporúčali použiť curriculum učenie: najskôr samostatne trénovať priblíženie ku kocke, potom zdvihnutie a až nakoniec celý presun do air-goal cieľa. Pomohlo by aj viac seedov, dlhší tréning a doladenie learning rate, batch size, rolloutov a clip range.

Reward ablation treba brať opatrne. Rozpočet 300k krokov bol krátky, takže neslúžil ako konečné riešenie. Dense reward bol stabilnejší, shaped reward lepšie opisoval fázy úlohy a penalizácia kolízií znížila tréningové kontakty, ale nezlepšila finálny pick-and-place výkon.

IX. ZÁVER

V práci sme implementovali a vyhodnotili RL systém pre riadenie robotického ramena v úlohe Fetch Pick and Place. Porovnali sme PPO a SAC a doplnili sme aj menšiu analýzu reward funkcií. Najlepší výsledok dosiahol SAC na shaped air-goal úlohe s 1 miliónom krokov, kde získal 100/100 úspešných cieľov, uchopení aj pick-and-place epizód. PPO v rovnakom nastavení úlohu nevyriešilo. Dodatočný SAC curriculum experiment dosiahol rovnakú 100% úspešnosť pre tri seedy a zastavil sa po 400k až 600k krokoch. Pre túto úlohu sa preto ako vhodnejší ukázal SAC, aj keď jeho tréning trval výrazne dlhšie. Do budúcnosti by sme ešte chceli otestovať dlhší reward ablation rozpočet, curriculum variant pre PPO a presnejšie načasovanie penalizácie kolízií.

REFERENCES

- [1] Farama Foundation, “Fetch Pick and Place Environment,” https://robotics.farama.org/envs/fetch/pick_and_place/, accessed: 2026-05-28.
- [2] Stable-Baselines3 Contributors, “Stable-Baselines3 Documentation,” <https://stable-baselines3.readthedocs.io/>, accessed: 2026-05-28.
- [3] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” *arXiv preprint arXiv:1707.06347*, 2017.
- [4] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine, “Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor,” in *Proceedings of the 35th International Conference on Machine Learning*, 2018, pp. 1861–1870.
- [5] M. Andrychowicz, F. Wolski, A. Ray, J. Schneider, R. Fong, P. Welinder, B. McGrew, J. Tobin, P. Abbeel, and W. Zaremba, “Hindsight experience replay,” in *Advances in Neural Information Processing Systems*, 2017.