

Autonómne riadenie robotického ramena

Cieľ projektu:


Naučiť RL agenta autonómne riadiť robotické rameno tak, aby dokázalo uchopiť objekt a presunúť ho na cieľové miesto.

Úloha: Fetch Pick and Place

Použité algoritmy: PPO, SAC

Hodnotené kritériá: dĺžka učenia, úspešné uchopenia, kolízie, stabilita učenia

Bc. Ivan Demchenko, Bc. Danylo Kravchenko
Technická univerzita v Košiciach



Výsledok tréningu: úspešné uchopenie a presun objektu

Prostredie a akčný priestor

Použili sme prostredie **FetchPickAndPlace-v4** z knižnice **Gymnasium-Robotics** v simulátore **MuJoCo**.

Pozorovanie:

Agent dostáva informácie o stave prostredia:

- observation
- achieved_goal
- desired_goal

Akčný priestor:

Akcia pozostáva zo 4 spojitých hodnôt:

- 3D pohyb gripperu
- otvorenie / zatvorenie gripperu

Evaluácia:

Tréning a porovnanie algoritmov sme hodnotili na základe:

- dĺžky epizódy
- úspešnosti uchopenia
- počtu kolízií
- stability učenia

- **Nastavenie experimentu:** epizóda mala maximálne 50 krokov, evaluácia prebiehala deterministicky na 100 epizódach.


Dôležitá oprava: air-goal

Pri základnom nastavení vznikol neželaný shortcut: agent vedel posunúť kocku po stole bez reálneho uchopenia.

Pred úpravou

Cieľ mohol byť blízko stola.

Úspech preto nemusel znamenať uchopenie.




Tlačenie stačilo

Po úprave

Cieľ je nad stolom.

Bez zdvihnutia objektu sa úspech nedá dosiahnuť.



Pick-and-place

Air-goal wrapper bol kľúčový, aby metrika success zodpovedala reálnej manipulácii.

Porovnané algoritmy

Tím sa rozdelil: SAC časť riešil Danylo, PPO časť Ivan.

PPO

On-policy algoritmus.

Aktualizuje politiku pomocou klipovanej objective funkcie.

Je rýchly, ale úspešné pokusy sa pri sparse odmene využívajú menej efektívne.

SAC

Off-policy actor-critic algoritmus.

Používa replay buffer a entropiu pri sparse odmene HER.

Tréning je pomalší, ale získané skúsenosti sa využívajú opakovane.

Finálne výsledky ukázali, že samotná rýchlosť tréningu nestačí. Dôležitá bola aj použitá politika a práca so skúsenosťami.

Reward funkcie

Testovali sme štyri typy odmien: sparse, dense, shaped a penalized shaped reward.

Sparse

odmena až pri splnení cieľa

Dense

hustejší signál podľa vzdialenosti od cieľa

Shaped

priblíženie ku kocke, zdvihnutie objektu, presun k cieľu, bonus za úspech

Penalized

shaped reward + trest za neočakávané kolízie

Záver z odmien: shaped reward mal väčšie kolísanie, ale poskytol agentovi lepší signál pre dlhý SAC tréning.

Experimentálny setup

Konfigurácie boli uložené v YAML súboroch a každý tréningový beh ukladal model, metadáta a logy.

Finálne porovnanie

- Algoritmy: PPO vs SAC
- Reward: shaped
- Cieľ: air-goal
- Trvanie: 1 000 000 krokov

100

deterministických eval epizód

Reward ablation

- Rewardy: dense / shaped / penalized
- Algoritmy: PPO aj SAC
- Trvanie: 300 000 krokov
- Evaluácia: 100 epizód

42

seed pre porovnateľnosť

Akcelerácia

- CUDA device
- 8 paralelných envs
- SubprocVecEnv
- gradient_steps = 8

50

krokov / epizóda

Reward ablation: 300k nestačilo

Krátky tréning ukázal rozdiely v stabilite odmien, ale ešte nevyriešil air-goal manipuláciu.


Najdôležitejší záver

Dense reward mal nižšie kolísanie podľa rolling std.

Shaped reward poskytoval viac medzikrokového signálu.

Penalizácia kolízií pri 300k krokoch nepriniesla jasné zlepšenie.

Všetky 300k konfigurácie dosiahli maximálne 3/100 goal success.



Graf porovnáva čas tréningu, úspešnosť evaluácie a kolísanie rewardu pre PPO a SAC pri rôznych reward funkciách.

Finálny výsledok: SAC vyriešil prísnejšiu úlohu

1M krokov, shaped reward, air-goal target, 100 eval epizód

PPO

0/100

goal, grasp aj pick úspech


Tréning bol rýchly: 265.6 s.
Politika však nebola použiteľná.

SAC

100/100


goal, grasp aj pick úspech

Tréning trval 8712.3 s.
Výsledná politika objekt zdvihla a premiestnila.



Kolízie pri finálnej
evaluácii boli 0,00 pre
PPO aj SAC.

Pri SAC je to dôležité,
pretože nulové kolízie
prišli spolu s
úspešnou
manipuláciou.



Záver a čo by sa robilo ďalej

SAC bol pomalší, ale v tejto úlohe spoľahlivo vyriešil pick-and-place.

Hlavné závery

1. Air-goal zabránil push-only riešeniu.
2. Shaped reward bol najlepší kandidát pre dlhší SAC tréning.
3. SAC využil replay buffer a exploráciu lepšie než PPO.
4. 300k reward ablation nestačil na finálne závery o úspešnosti.

Ďalšie kroky

Viac seedov, dlhšia reward ablation, presnejšia penalizácia kolízií, porovnanie PPO po ďalšom ladení.

Výsledok:

100/100 úspešných pick-and-place epizód.

SAC agent po 1M krokoch spoľahlivo zdvihol objekt a presunul ho na cieľové miesto.

Použitá konfigurácia:

SAC + shaped reward + air-goal target.

Prečo je to dôležité:

úspech nebol dosiahnutý tlačením objektu, ale reálnou - pick-and-place manipuláciou.